LateBranch: positive report

三个问题，一条逻辑：任务缺口 → 可干预的等位接口 → 已测量的预测与 pattern 收益。

本报告聚焦已完成的正向证据，并给出相应图表。预测结果使用固定 seed 13 的新 count-only 协议；解释图使用明确标注的历史模型。它是聚焦报告，不代表所有消融已完成或最终 RECOMB 稿。

1. 为什么预训练 DNABERT 不能直接给出 allelic log-ratio？

缺的是任务定义和监督接口。 DNABERT-2 的预训练学习 DNA token 的上下文表示；某个 token 在序列中有多可能，不等于该等位基因在某种组织和 assay 中贡献多少分子信号。这里的目标是

$$\eta = \ln \frac{\mu_{\text{ALT}}}{\mu_{\text{REF}}}, \qquad p_{\text{ALT}} = \sigma(\eta),$$

其中 μ 是给定条件下的期望等位信号。要把表示变成这个有方向、有幅度的量，需要指定 REF/ALT 对照、实验条件和与计数相连的学习目标。**这不是 DNABERT 没有监督预测能力：微调后的 Vanilla 也能学习该任务。**表 1 的目的，是说明 LateBranch 补齐了哪一层接口。

Table 1: 从预训练表示到等位计数，必须明确的三个对应关系。

问题	预训练本身提供什么	本任务增加什么
预测对象	上下文 token 表示/概率	同一背景中的 ALT 与 REF 对比
条件	DNA 序列上下文	assay 与 tissue 条件
输出含义	序列统计量	有符号的 η、ALT fraction 及计数似然

2. Interpretability insight 如何变成注入与读出设计？

把固定背景、改变一个内部变量、观察下游响应做成模型的计算接口。自然 REF 先经过共享前缀；在覆盖 SNV 的 token 上，加入候选碱基相对 REF 的残差。四个候选使用相同后续权重和同一个 scalar head，因此可以在统一坐标上检查候选引起的表示、attention 和输出变化。这个思路借鉴 intervention-based model interpretation；它是设计动机，不是已经识别出某个生物学因果模块的结论。

$$\phi(o,\ell) = \left(\frac{o}{\ell}, \frac{\ell-1-o}{\ell}, \frac{1}{\ell}, \frac{\ln \ell}{5}\right), \qquad \delta_b = gP(e_b - e_r) \odot \left[1 + \tfrac{1}{2}\tanh(W\phi)\right].$$

这里 o 是 token 内的零起始偏移，ℓ 是 token 跨度；W 零初始化，REF 候选的残差严格为零。自然 REF 坐标不随候选重新切词。图 1 展示精确位置编码、terminal assay/tissue FiLM 和 focal-query attention。候选 potential 的差定义 $\hat{\eta} = q_{\text{ALT}} - q_{\text{REF}}$；beta-binomial 计数监督再把它与 ALT/total 观测联系起来。**enable 来自候选编码、带条件的相对读出和监督目标的组合。**第八层是当前配置，不能由这段构造直接推出最优深度或位置模块带来提升。

方法背景：Zhou et al., DNABERT-2, ICLR 2024；Geiger et al., Causal Abstractions of Neural Networks, NeurIPS 2021。上述连接到等位预测的具体接口是本项目的设计，不是这些文献已验证的结论。

问题 2 的图证据：候选如何进入共享上下文

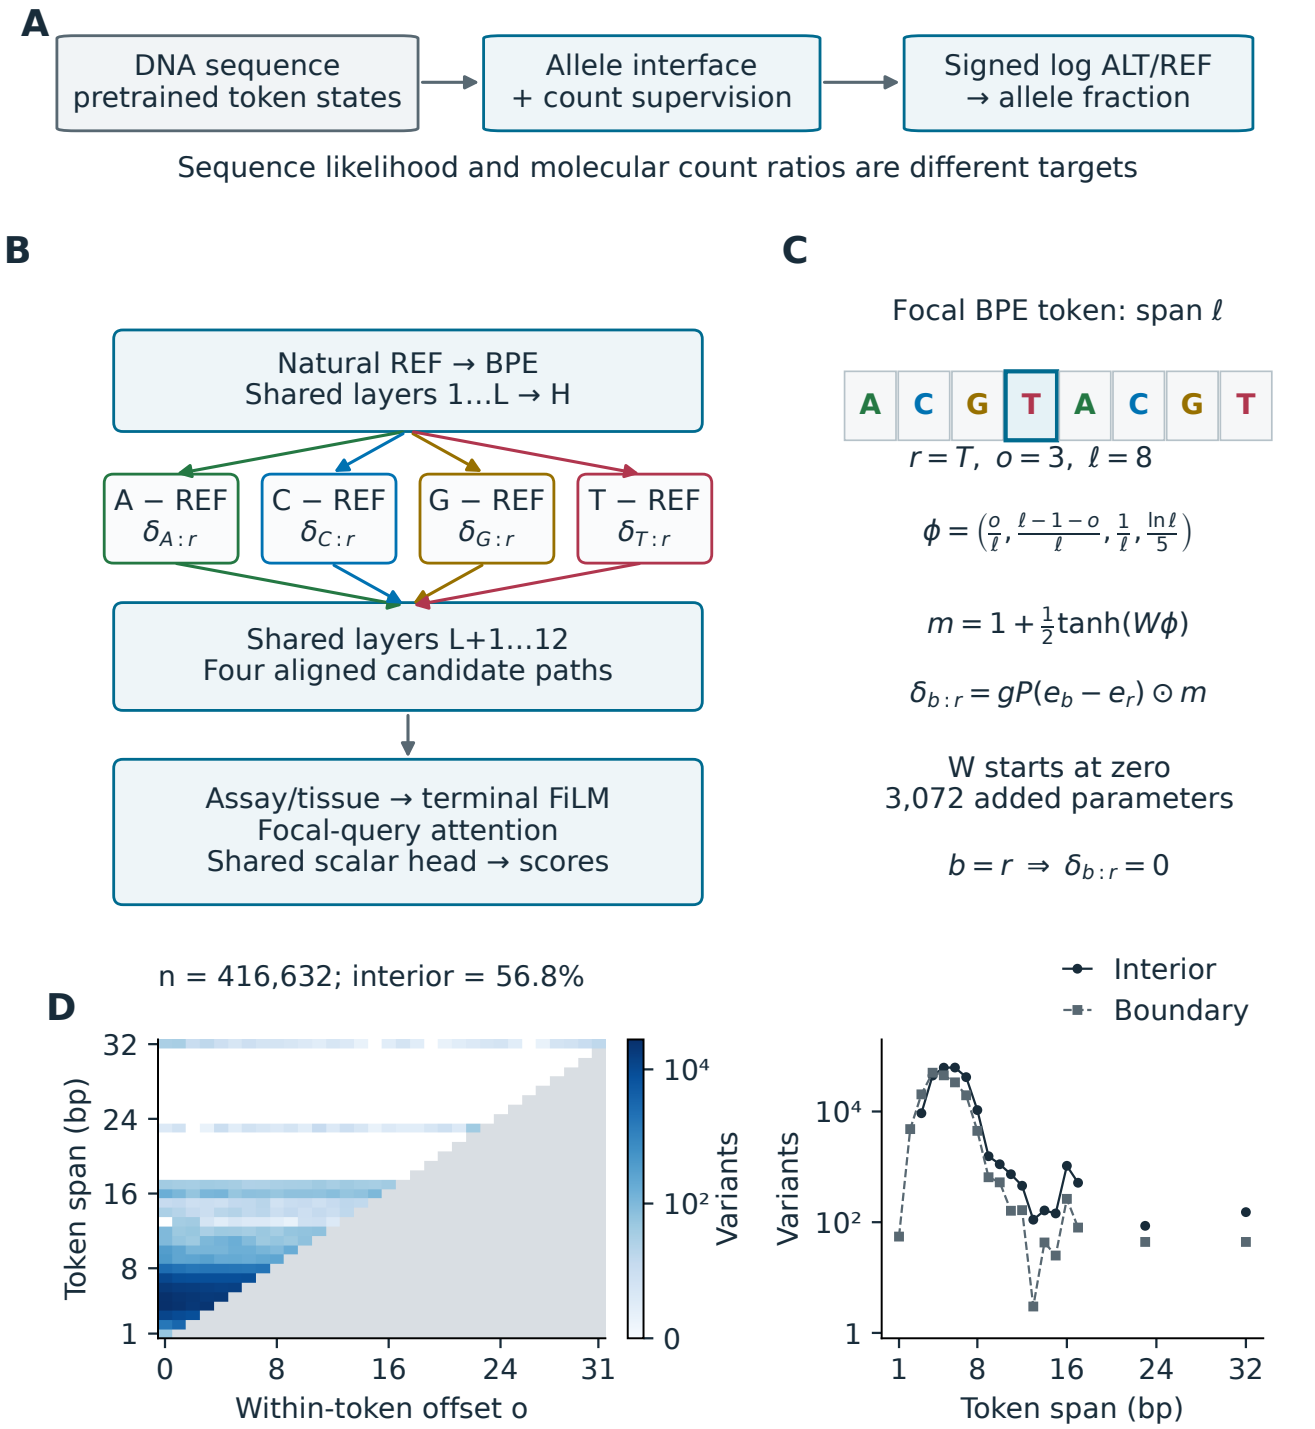


Figure 1: A，计数监督把预训练表示连接到有方向的等位输出。B，共享自然 REF 前缀、局部候选残差、共享后续层及带 assay/tissue 条件的读出。C，精确 token 内位置编码；示例序列仅解释坐标。D，全部 416,632 个变异的真实 offset/span 分布：56.8% 位于 token 内部；灰色表示不可能坐标，白色表示合法但未观测到的组合。设计使干预变量和比较坐标明确，其预测效益需要由实验检验。

3. 已有结果支持多大的收益，以及什么 pattern insight？

预测收益最明确地体现在校准后的染色体留出 NLL。相对原 mean-pool Vanilla，LateBranch 在 chr19–22 的 NLL 降低 0.002456 nats/观测，95% 配对区间为 $[-0.003323, -0.001650]$。Window 划分的点估计也较低，但区间跨零。两种划分上，校准后的计数似然均优于固定 $p = 0.5$，支持模型学习到了超出恒定均值的信号。表 2、3 和图 2 给出比较条件；raw 染色体结果并不改善，因此此处的收益明确包括独立校准。

Table 2: 固定 seed 13 的完整总体端点；NLL 越低越好。Window 有 97,662 条观测，chr19–22 有 249,984 条。

Endpoint	Window LB	Window V	Chr LB	Chr V
Raw NLL	2.766753	2.772797	2.730127	2.729006
Calibrated NLL	2.765614	2.771044	2.717552	2.720008
Fixed $p = 0.5$ NLL	2.818306	2.818306	2.722556	2.722556
Pearson r (cal.)	0.289	0.271	0.186	0.162
Spearman (cal.)	0.077	0.090	0.024	0.036
Direction all (%)	52.27	52.45	50.64	51.02

Table 3: 校准后 NLL 的配对差与 95% 区间（nats/观测）；负值有利于 LateBranch。

Split	Contrast	Δ NLL	95% interval
Window	LB − Vanilla	-0.005430	[-0.014758, 0.003903]
Window	LB − $p = 0.5$	-0.052692	[-0.071166, -0.036154]
Chr19–22	LB − Vanilla	-0.002456	[-0.003323, -0.001650]
Chr19–22	LB − $p = 0.5$	-0.005004	[-0.006364, -0.003746]

Pattern 收益是更多焦点敏感片段能够被恢复。在历史的 outcome-stratified 解释样本中，覆盖率从 252/1,280（19.69%）增至 486/1,280（37.97%），提高 18.28 个百分点，95% 区间为 $[15.16, 21.33]$。五个 assay 的点估计均提高（表 4）。位置平移对照中，两模型覆盖率分别为 6.25% 和 5.86%，说明原位置的结构比简单错位对照更集中。图 3 展示真实 ATCG 信息量及贡献 logos；图 4 将 pattern、碱基扰动与新增 head attention 放在共同坐标中，便于检查模型依赖的局部序列结构。

Table 4: 历史解释样本中的 focal-seqlet coverage；差值与区间以百分点计。各 assay 256 条，合计 1,280 条。

Assay	LateBranch	Vanilla	Δ pp	95% interval
CTCF	117/256	51/256	25.78	[18.36, 33.07]
H3K27ac	100/256	65/256	13.67	[6.27, 21.09]
H3K4me3	82/256	52/256	11.72	[5.12, 18.18]
ATAC-seq	116/256	44/256	28.12	[21.47, 34.77]
RNA-seq	71/256	40/256	12.11	[5.47, 18.99]
All	486/1280	252/1280	18.28	[15.16, 21.33]

示例具体呈现了 ATAC/部分 H3K4me3 的 GC-rich 敏感结构，以及 RNA 的 A-rich 结构，把模型输出连接到可检查的 assay 相关序列偏好。它们支持后续生物学假说；catalog 名称仍只是候选注释。

可写入贡献的含义。 LateBranch 提供了可学习、可干预、可复用的 allele 接口；当前证据支持特定校准计数端点的收益，以及历史模型中更广的 focal-seqlet coverage。历史三 ALT 查询的端到端时间比为 1.946–1.997，支持该工作负载下约两倍复用收益；单 ALT 没有加速。**Pattern coverage 不是 TF 识别准确率，attention 也不是带符号的因果贡献。**

统计口径：NLL 区间为 5,000 次 window-component 配对重采样，条件于 seed-13 checkpoint 与已拟合校准；是逐比较区间，不含训练种子方差。Pattern 区间也用 5,000 次 component 配对重采样，条件于该分层样本。历史研究看过 69 个配置的测试结果，本报告保留回顾性范围。表 2 的方向使用全部非平局计数，分母为 85,985/216,019；pattern 表使用另一历史 balanced 模型及分层抽取的解释样本，不能归因于新增位置 gate，也不估计总体 motif 发生率。

问题 3 的预测图证据：留出划分与独立校准

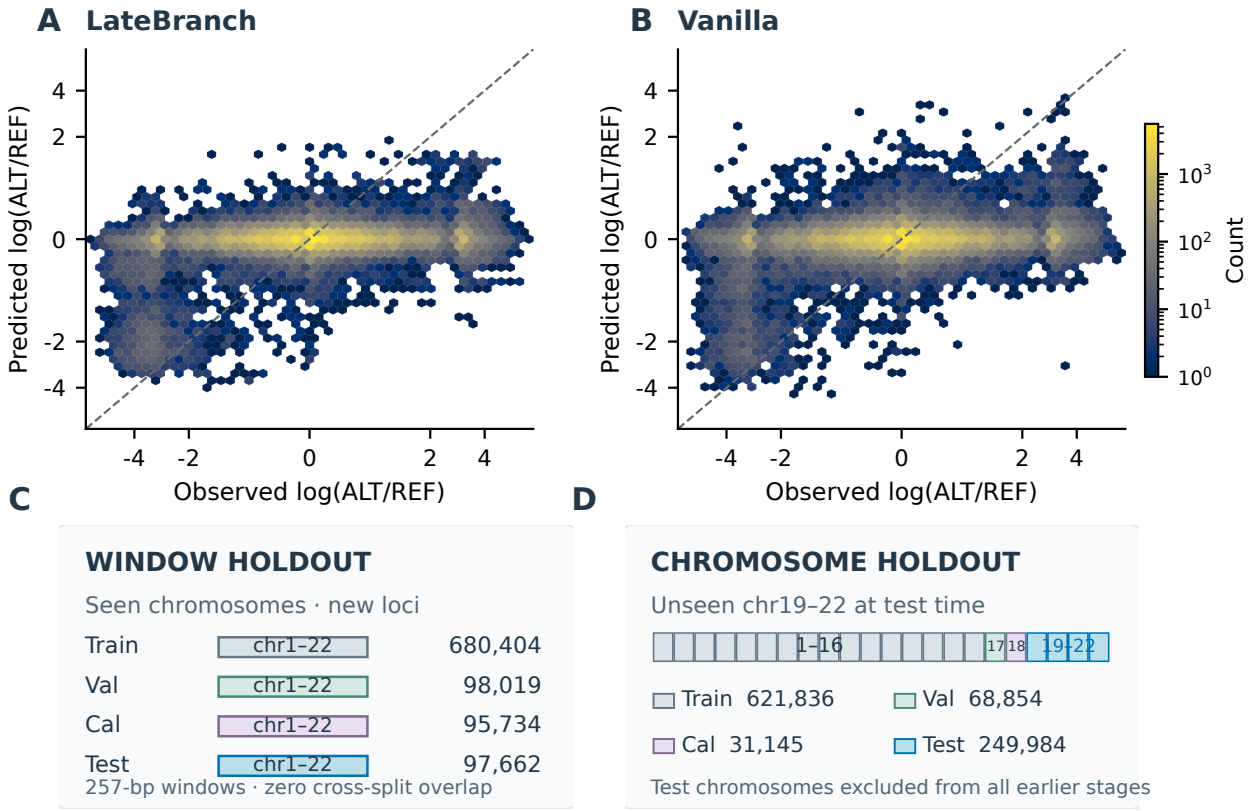


Figure 2: A、B，全部 97,662 条 window test 观测的校准预测；两图使用相同 asinh 坐标、完整范围和对数密度色标，刻度仍标自然对数单位。C，window 划分在 chr1–22 各自抽取互不重叠的 257-bp 序列窗口，检验已见染色体上的新位点。D，染色体划分使用 chr1–16 训练、chr17 验证、chr18 校准、chr19–22 测试，检验未见染色体。C、D 的色带为流程示意，宽度不代表基因组跨度或样本比例；数字为观测数。E，固定模型的 raw log-ratio 在独立校准集上按 assay 拟合尺度 $s_a \in [0, 3]$，训练集估计的离散度保持不变；所列 LateBranch 实际拟合值均小于 1，表明 raw 幅度需收缩，测试集不参与拟合。F，仅列 LateBranch 在两个留出测试集上校准前后的 beta-binomial NLL 与降低幅度；若省略校准，损失相应增加。数值是固定 seed-13 的描述性点估计，不是重新训练的不确定性区间；与 Vanilla 的比较见表 2、3。

问题 3 的 pattern 图证据：哪些序列结构可被恢复

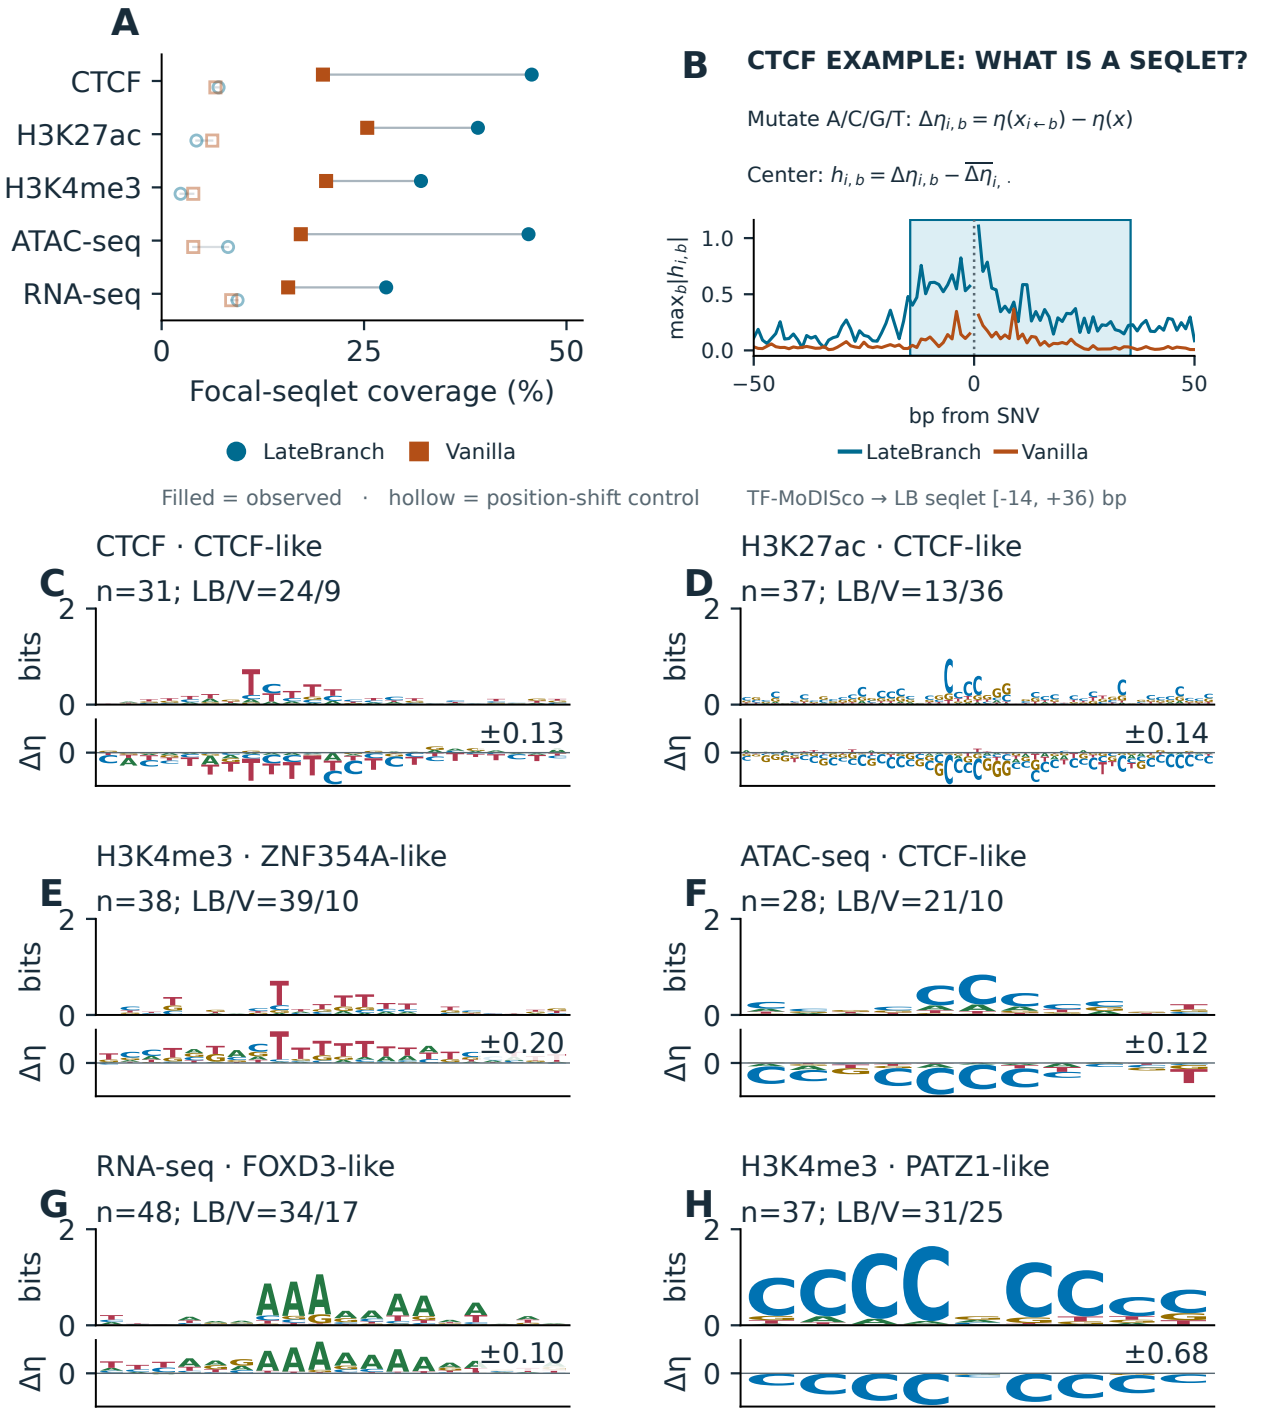
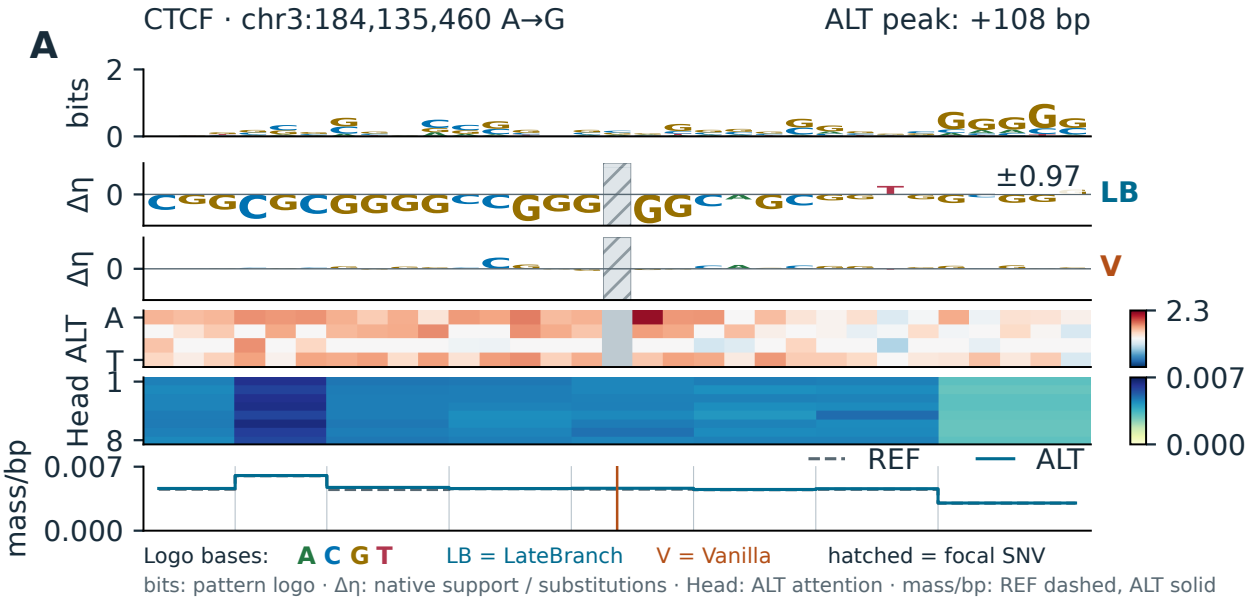
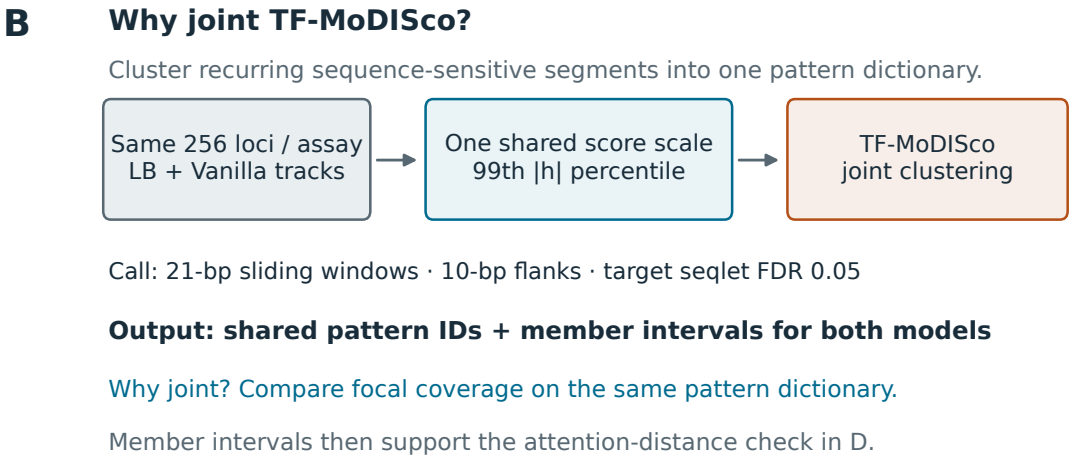


Figure 3: 历史 balanced 实验。A，五个 assay 的 focal-seqlet coverage；蓝色圆点为 LateBranch，橙色方块为 Vanilla，实心为观测、空心为位置平移对照。B，真实 CTCF 病例的四碱基替换响应 $\Delta\eta_{i,b}$ 逐位中心化得到 $h_{i,b}$；曲线为两模型的 $\max_b |h_{i,b}|$，蓝色区间是归档 TF-MoDISco 的 LateBranch seqlet $[-14, +36)$ bp，覆盖焦点 SNV，区间不是曲线阈值。C–G，各 assay 中按支持位点数选择的 joint pattern；H，已审计的 PATZ1-like H3K4me3 pattern。上方 logo 为序列信息量（bits），下方为归档的带符号贡献并保留对称尺度。Catalog 相似性不证明 TF 身份；H3K27ac 示例也保留更少的 LateBranch seqlets。

问题 3 的对齐图证据：pattern 与 head attention 在哪里相遇





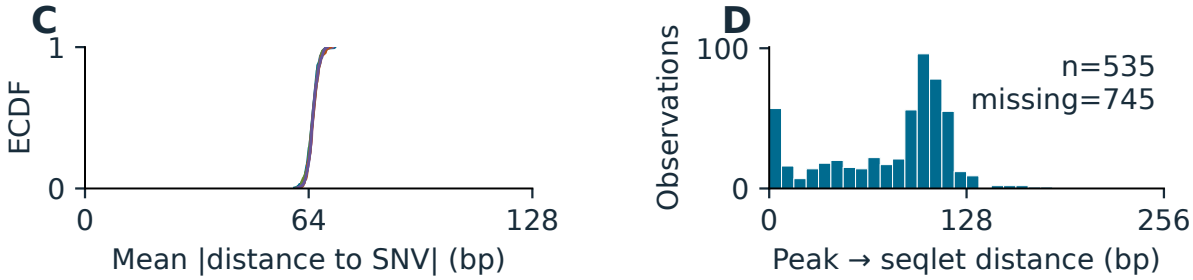


Figure 4: 历史 balanced 实验。A，CTCF 病例的 pattern logo、两模型原生碱基敏感性、LateBranch 四碱基替换响应、八个 ALT readout heads 及 REF/ALT 平均 attention；图例标明颜色与线型，SNV 处扰动被遮蔽，热图尺度为 ± 2.3。B，联合 TF-MoDISco 聚类每个 assay 中相同 256 位点的两模型轨迹；共用 99 百分位尺度，调用设置 21-bp 窗口、10-bp flank、0.05 内部 seqlet FDR 目标。共同 pattern 字典用于 coverage 比较，成员坐标用于 D。C，1,280 条的平均绝对 attention 距离。D，attention peak 到最近 LateBranch seqlet 的距离；745 条无 seqlet 者保留缺失。attention 在 token 内均摊；内部 FDR 与几何对齐不证明 TF 位点或因果贡献。

数据与复核：预测部分来自已完成的 14 组 frozen-reference 评估及独立数值复核；报告只聚焦 Vanilla/常数参照，不作全基线排名。配套 CSV 保留全部参考结果，source_manifest.json 记录来源与哈希。历史解释来源为 motif_audit 和已回放的 readout attention。制图流程使用 Scientific Agent Skills，并依其引用要求注明：Kassis, T., Agarwal, V., He, Y., Patel, D., & Brueckner, A. M. (2026), Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents。